

**Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный университет имени М.В.Ломоносова»**

Направление «Фундаментальная математика»

Килимчук Иван Вячеславович

**«Прогнозирование временных рядов»
Курсовая работа**

Научный руководитель:
к.ф.-м.н., доцент М.П. Заплетин

Москва, 2026

Содержание

1	Введение	3
2	Постановка задачи	3
3	Некоторые свойства временных рядов	3
3.1	Стационарность временных рядов	3
3.2	Стабилизация дисперсии	4
3.3	Дифференцирование	5
3.4	Автокорреляция	6
4	Методы решения	7
4.1	Экспоненциальное сглаживание	7
4.2	Модель Хольта	8
4.3	Модель Хольта-Уинтерса	9
4.4	Модель авторегрессии $AR(p)$	10
4.5	Модель скользящего среднего $MA(q)$	11
4.6	Модель $ARMA(p, q)$	11
4.7	Модель $ARIMA(p, d, q)$	12
4.8	Оценка p и q	12
4.9	Прогнозирование с помощью $ARIMA$	13
4.10	Модель $SARIMA$	13
4.11	Модель $ARIMAX$	13
4.12	$ARIMA$ с несколькими сезонностями	14
5	Реализация моделей на реальных данных	14
6	Заключение	19
7	Список литературы	19

1 Введение

Временной ряд: $y_1, \dots, y_T, \dots; y_t \in \mathbb{R}$ — значения признака, измеренные через постоянные временные интервалы.

Главная особенность временных рядов:

- В классических задачах анализа данных предполагается независимость наблюдений
- При прогнозировании временных рядов, наоборот, мы надеемся, что значения ряда в прошлом содержат информацию о его поведении в будущем

Компоненты временных рядов:

- **Тренд** — плавное долгосрочное изменение уровня ряда.
- **Сезонность** — циклические изменения уровня ряда с постоянным периодом.
- **Цикл** — изменения уровня ряда с переменным периодом (экономические циклы).

2 Постановка задачи

Найти функцию f :

$$y_{T+h} \approx f(y_T, \dots, y_1, h)$$

где $h \in \{1, 2, \dots, H\}$, H — горизонт прогнозирования.

3 Некоторые свойства временных рядов

3.1 Стационарность временных рядов

Ряд $y_1, \dots, y_T$ **стационарен в узком смысле**, если $\forall t_1, \dots, t_n \forall \tau y_{t_1}, \dots, y_{t_n}$ и $y_{t_1+\tau}, \dots, y_{t_n+\tau}$ имеют одинаковое распределение.

Ряд $y_1, \dots, y_T$ **стационарен в широком смысле**, если его математическое ожидание не зависит от времени и корреляционная функция зависит от аргументов только через их разность: $\mathbb{E}[y_t] = \text{const}$, $R_y(t_1, t_2) = R_y(t_1 + \tau, t_2 + \tau) \forall t_1, t_2 \forall \tau$.

Ряд стационарен в узком смысле $\Rightarrow$ ряд стационарен в широком смысле.

Многие работы по прогнозированию временных рядов основываются на анализе стационарных рядов. Характеристики таких рядов (математическое ожидание, дисперсия) не зависят от времени, поэтому прогнозирование таких рядов производится значительно

проще и точнее, чем в случае нестационарных рядов. На практике чаще всего используют стационарность в широком смысле.

□ тренд $\Rightarrow$ нестационарность

□ сезонность $\Rightarrow$ нестационарность

Критерий KPSS (Kwiatkowski-Philips-Schmidt-Shin)

ряд: $y = y_1, \dots, y_T$;

нулевая гипотеза: H_0 : ряд y стационарен;

альтернатива: H_1 : ряд y описывается моделью вида $y_t = \alpha y_{t-1}$;

статистика:

$$KPSS(y) = \frac{1}{T^2} \sum_{i=1}^T \left(\sum_{t=1}^i y_t \right)^2 / \lambda^2;$$

$KPSS(y)$ при H_0 имеет табличное распределение.

Критерий Дики-Фуллера

временной ряд:

$$y^T = y_1, \dots, y_T;$$

нулевая гипотеза:

$$H_0 : \text{ряд нестационарен};$$

альтернатива:

$$H_1 : \text{ряд стационарен};$$

статистика: неважно;

нулевое распределение: табличное.

3.2 Стабилизация дисперсии

Для рядов с монотонно меняющейся дисперсией можно использовать стабилизирующие преобразования.

Часто используют логарифмирование.

Преобразования Бокса-Кокса

$$y'_t = \begin{cases} \ln y_t, & \lambda = 0, \\ \frac{y_t^\lambda - 1}{\lambda}, & \lambda \neq 0. \end{cases}$$

Обратное преобразование прогноза

После построения прогноза для трансформированного ряда его нужно преобразовать в прогноз исходного:

$$\hat{y}_t = \begin{cases} \exp(\hat{y}'_t), & \lambda = 0, \\ (\lambda \hat{y}'_t + 1)^{1/\lambda}, & \lambda \neq 0. \end{cases}$$

3.3 Дифференцирование

Дифференцирование ряда — переход к попарным разностям его соседних значений:

$$y_1, \dots, y_T \longrightarrow y'_2, \dots, y'_T,$$

$$y'_t = y_t - y_{t-1}.$$

Дифференцированием можно стабилизировать среднее значение ряда и избавиться от тренда и сезонности.

Может применяться неоднократное дифференцирование; например, для второго порядка:

$$y_1, \dots, y_T \longrightarrow y'_2, \dots, y'_T \longrightarrow y''_3, \dots, y''_T,$$

$$y''_t = y'_t - y'_{t-1} = y_t - 2y_{t-1} + y_{t-2}.$$

Сезонное дифференцирование

Сезонное дифференцирование ряда — переход к попарным разностям его значений в соседних сезонах:

$$y_1, \dots, y_T \longrightarrow y'_{s+1}, \dots, y'_T,$$

$$y'_t = y_t - y_{t-s}.$$

3.4 Автокорреляция

$$\rho_\tau = \frac{Cov(y_t, y_{t+\tau})}{\mathbb{D}y_t} = \frac{R_y(t, t + \tau)}{\mathbb{D}y_t}$$

$\rho_\tau \in [-1, 1]$, τ — лаг автокорреляции.

Выборочная автокорреляция:

$$r_\tau = \frac{\sum_{t=1}^{T-\tau} (y_t - \bar{y})(y_{t+\tau} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}$$

Автокорреляционная функция (ACF) — это значение автокорреляции при разных лагах. Коррелограмма — это график автокорреляционной функции.

Значимость автокорреляции

временной ряд: $y^T = y_1, \dots, y_T$;

нулевая гипотеза: $H_0 : \rho_\tau = 0$;

альтернатива: $H_1 : \rho_\tau \neq 0$;

статистика: $T(y^T) = \frac{r_\tau \sqrt{T-\tau-2}}{\sqrt{1-r_\tau^2}}$;

распределение при H_0 : $T(y^T) \sim St(T - \tau - 2)$

Q-критерий Льюнга-Бокса

ряд ошибок прогноза:

$$\varepsilon^T = \varepsilon_1, \dots, \varepsilon_T;$$

нулевая гипотеза:

$$H_0 : \rho_1 = \dots = \rho_L = 0;$$

альтернатива:

$$H_1 : H_0 \text{ неверна};$$

статистика:

$$Q(\varepsilon^T) = T(T+2) \sum_{\tau=1}^L \frac{r_\tau^2}{T-\tau};$$

распределение при H_0 :

χ_{L-K}^2 , где K - число настраиваемых параметров модели ряда.

4 Методы решения

4.1 Экспоненциальное сглаживание

$$\hat{y}_{t+1|t} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \dots,$$

где $\hat{y}_{t+h|t}$ — прогноз значения y_{t+h} в момент вр. t , $\alpha \in (0, 1)$ — параметр сглаживания.

Рекуррентная форма записи:

$$\hat{y}_{t+1|t} = \alpha y_t + (1 - \alpha)\hat{y}_{t|t-1}$$

Свойства:

- При $\alpha \approx 1$ модель придаёт больший вес последним точкам: $\hat{y}_{T+1|T} \approx y_T$.
- При $\alpha \approx 0$ максимальное сглаживание: $\hat{y}_{T+1|T} \approx \bar{y}$.
- Оптимальное значение параметра α^* :

$$\alpha^* = \arg \min_{\alpha} \sum_{t=t_0}^T (\hat{y}_t(\alpha) - y_t)^2$$

Покажем, что сглаженное значение соответствует задаче

$$\sum_{t=0}^T \beta^{T-t} (y_t - x)^2 \rightarrow \min_x$$

Приравниваем производную по x к нулю:

$$\frac{\partial}{\partial x} \sum_{t=0}^T \beta^{T-t} (y_t - x)^2 = -2 \sum_{t=0}^T \beta^{T-t} (y_t - x) = 0$$

$$\sum_{t=0}^T \beta^{T-t} y_t = x \sum_{t=0}^T \beta^{T-t} = x \sum_{t=0}^T \beta^t$$

$$x = \frac{\sum_{t=0}^T \beta^{T-t} y_t}{\sum_{t=0}^T \beta^t}$$

При $T \rightarrow \infty$ $\sum_{t=0}^{\infty} \beta^t = \frac{1}{1-\beta}$. Поэтому $x \approx (1 - \beta) \sum_{t=0}^T \beta^{T-t} y_t$.

$$x \approx (1 - \beta)y_T + (1 - \beta)\beta \sum_{t=0}^{T-1} \beta^{T-1-t} y_t \approx (1 - \beta)y_T + \beta \hat{y}_{T|T-1}$$

Получили модель экспоненциального сглаживания для $\beta = 1 - \alpha$.

4.2 Модель Хольта

Аддитивный линейный тренд:

$$\hat{y}_{t+d|t} = a_t + b_t \cdot d$$

$$a_t = \alpha y_t + (1 - \alpha)(a_{t-1} + b_{t-1})$$

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1}$$

Мультипликативный линейный тренд:

$$\hat{y}_{t+d|t} = a_t \cdot b_t^d$$

$$a_t = \alpha y_t + (1 - \alpha)(a_{t-1} \cdot b_{t-1})$$

$$b_t = \beta \frac{a_t}{a_{t-1}} + (1 - \beta)b_{t-1}$$

Заметим, что $\hat{y}_{t+1|t} = a_t + b_t$, $\hat{y}_{t+1|t+1} = a_{t+1} + b_{t+1} \cdot 0 = a_{t+1}$.

Поэтому хотим, чтобы $a_{t+1} \approx a_t + b_t$. Обозначим $\Delta y_t = a_t - a_{t-1}$.

Рассмотрим задачу прогноза $\Delta \hat{y}_{t+1|t} = b$:

$$\sum_{i=0}^t (1 - \beta)^{t-i} (\Delta y_i - b)^2 \rightarrow \min_b$$

Её решение:

$$b \approx \beta \Delta y_t + (1 - \beta) \Delta \hat{y}_{t|t-1}$$

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1}$$

Покажем, что a_t соответствует задаче

$$\sum_{i=0}^t (1 - \alpha)^{t-i} (y_i - a)^2 \rightarrow \min_a$$

$$a \approx \alpha y_t + (1 - \alpha) \hat{y}_{t|t-1}$$

$$a_t = \alpha y_t + (1 - \alpha)(a_{t-1} + b_{t-1})$$

4.3 Модель Хольта-Уинтерса

Аддитивная сезонность:

$$\hat{y}_{t+d|t} = a_t + db_t + s_{t-m+(d \bmod m)}$$

$$a_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(a_{t-1} + b_{t-1})$$

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma(y_t - a_t) + (1 - \gamma)s_{t-m},$$

где m — длина сезона.

Мультипликативная сезонность:

$$\hat{y}_{t+d|t} = a_t \cdot s_{t-m+(d \bmod m)}$$

$$a_t = \alpha \left(\frac{y_t}{s_{t-m}} \right) + (1 - \alpha)a_{t-1}$$

$$s_t = \gamma \left(\frac{y_t}{a_t} \right) + (1 - \gamma)s_{t-m}$$

Мультипликативная сезонность с линейным трендом:

$$\hat{y}_{t+d|t} = (a_t + d \cdot b_t) \cdot s_{t-m+(d \bmod m)}$$

$$a_t = \alpha \frac{y_t}{s_{t-m}} + (1 - \alpha)(a_{t-1} + b_{t-1})$$

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma \frac{y_t}{a_t} + (1 - \gamma)s_{t-m}$$

4.4 Модель авторегрессии AR(p)

$$y_t = \alpha + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t,$$

где y_t — стационарный ряд, ε_t — гауссовский белый шум, т.е. $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ и независимы.

Введём L — оператор сдвига: $Ly_t = y_{t-1}$, $L\varepsilon_t = \varepsilon_{t-1}$.

$$y_t = \alpha + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t$$

$$a(L)y_t = \alpha + \varepsilon_t,$$

$$\text{где } a(z) = 1 - \varphi_1 z - \dots - \varphi_p z^p.$$

Теорема. Процесс $AR(p)$ стационарен $\iff$ все комплексные корни $a(z) = 0$ лежат вне единичного круга.

Модель AR(1)

Пусть $y_t = \alpha + \varphi y_{t-1} + \varepsilon_t$, где $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$.

Характеристическое уравнение $1 - \varphi z = 0$ имеет корень $\lambda = 1/\varphi$.

Модель AR(1) стационарна $\iff |\varphi| < 1$.

Если ряд стационарен, то

$$\mathbb{E}[y_t] = \frac{\alpha}{1 - \varphi},$$

$$\mathbb{D}[y_t] = \frac{\sigma^2}{1 - \varphi^2},$$

$$\text{cov}(y_t, y_{t-h}) = R_y(t, t-h) = \varphi^h \cdot \frac{\sigma^2}{1 - \varphi^2}.$$

4.5 Модель скользящего среднего МА(q)

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q},$$

где y_t — стационарный ряд со средним μ , ε_t — гауссовский белый шум, т.е. $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ и независимы.

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} = \mu + b(L)\varepsilon_t,$$

$$\text{где } b(z) = 1 + \theta_1 z + \dots + \theta_q z^q.$$

Математическое ожидание и дисперсия y_t :

$$\mathbb{E}[y_t] = \mu$$

$$\mathbb{D}[y_t] = \sigma^2 (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2).$$

Теорема. Любой стационарный процесс представим в виде МА(∞).

4.6 Модель ARMA (p, q)

$$y_t = \alpha + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

$$a(L)y_t = \alpha + b(L)\varepsilon_t \text{ или } y_t = \mu + \frac{b(L)}{a(L)}\varepsilon_t,$$

$$\text{где } a(z) = 1 - \varphi_1 z - \dots - \varphi_p z^p, b(z) = 1 + \theta_1 z + \dots + \theta_q z^q.$$

4.7 Модель ARIMA (p, d, q)

ARIMA(p, d, q) для $y_t = \text{ARMA}(p, q)$ для ряда разностей порядка d ряда y_t .

$$a(L)(1-L)^d y_t = \alpha + b(L)\varepsilon_t \text{ или } (1-L)^d y_t = \mu + \frac{b(L)}{a(L)}\varepsilon_t$$

То есть многочлен $\tilde{a}(z) = a(z)(1-z)^d$ имеет d единичных корней.

Свойство: Позволяет учитывать нестационарность, в частности, тренд.

4.8 Оценка p и q

Частичная автокорреляция (PACF) — это корреляция ряда с собой после снятия линейной зависимости от предыдущих элементов ряда.

$$\gamma_h = \begin{cases} \text{corr}(y_{t+1}, y_t), & h = 1 \\ \text{corr}(y_{t+h} - y_{t+h}^{h-1}, y_t - y_t^{h-1}), & h \geq 2, \end{cases}$$

где y_t^{h-1} — линейная регрессия y_t на $y_{t-1}, y_{t-2}, \dots, y_{t-(h-1)}$:

$$y_t^{h-1} = \beta_1 y_{t-1} + \beta_2 y_{t-2} + \dots + \beta_{h-1} y_{t-(h-1)}$$

$$y_{t+h}^{h-1} = \beta_1 y_{t+h-1} + \beta_2 y_{t+h-2} + \dots + \beta_{h-1} y_{t+1}.$$

Начальное приближение p: последний значимый пик у PACF.

Начальное приближение q: последний значимый пик у ACF.

Далее используем поиск по сетке вокруг подобранных значений, минимизируя информационный критерий:

$$\text{AIC} = -2\ell^* + 2(p + q + 1) \quad \text{— критерий Акаике}$$

$$\text{BIC} = -2\ell^* + (\log T - 2)(p + q + 1) \quad \text{— критерий Шварца,}$$

где $\ell^* = \ln L_y(\hat{\theta}, \hat{\varphi}, \hat{\alpha})$ — логарифм функции правдоподобия.

4.9 Прогнозирование с помощью ARIMA

1. Стабилизация дисперсии.
2. Дифференцирование, если ряд не стационарен.
3. Выбор пилотных p и q по ACF и PACF.
4. Вокруг этих параметров подбираем оптимальную модель по AIC/BIC.
5. Пошаговое построение прогноза:
 - для $t \leq T$: $\varepsilon_t \implies \hat{\varepsilon}_t = y_t - \hat{y}_t$
 - для $t > T$: $\varepsilon_t \implies 0$
 - для $t > T$: $y_t \implies \hat{y}_t$

4.10 Модель SARIMA

ARIMA(p, d, q):

$$(1 - L)^d y_t = \mu + \frac{b(L)}{a(L)} \varepsilon_t$$

Пусть s — период сезонности ряда. Добавим в модель ARIMA(p, d, q) компоненты на значения в предыдущие сезоны.

SARIMA(p, d, q) $\times$ (P, D, Q) $_s$:

$$(1 - L)^d (1 - L^s)^D y_t = \mu + \frac{b(L)B(L^s)}{a(L)A(L^s)} \varepsilon_t,$$

где $a(z) = 1 - \varphi_1 z - \dots - \varphi_p z^p$, $b(z) = 1 + \theta_1 z + \dots + \theta_q z^q$,

$A(z) = 1 - \varphi_1^s z - \dots - \varphi_p^s z^P$, $B(z) = 1 + \theta_1^s z + \dots + \theta_q^s z^Q$.

4.11 Модель ARIMAX

ARIMA(p, d, q):

$$(1 - L)^d y_t = \mu + \frac{b(L)}{a(L)} \varepsilon_t$$

Пусть $x_t \in \mathbb{R}^n$ — процесс регрессоров, известный до начала прогноза.

Простой вариант:

$$(1 - L)^d y_t = \mu + \sum_{i=1}^n \frac{1}{a(L)} x_i^t + \frac{b(L)}{a(L)} \varepsilon_t$$

Общий случай:

$$(1 - L)^d y_t = \mu + \sum_{i=1}^n \frac{u_i(L)}{\nu_i(L)} x_i^t + \frac{b(L)}{a(L)} \varepsilon_t$$

4.12 ARIMA с несколькими сезонностями

Ряд Фурье — представление функции f с периодом τ в виде ряда:

$$f(x) = c + \sum_{k=1}^{\infty} \left(a_k \cos\left(\frac{2\pi kx}{\tau}\right) + b_k \sin\left(\frac{2\pi kx}{\tau}\right) \right)$$

Будем рассматривать такой временной ряд:

$$y_t = z_t + \sum_{i=1}^M \sum_{k=1}^{K_i} \left[\alpha_{ik} \cos\left(\frac{2\pi kt}{p_i}\right) + \beta_{ik} \sin\left(\frac{2\pi kt}{p_i}\right) \right],$$

где

- z_t — модель ARIMA
- M — количество сезонностей, $p_1, p_2, \dots, p_M$ — периоды всех сезонностей
- $\alpha_{i,k}, \beta_{i,k}$ — обучаемые веса в модели ARIMAX, отвечающие за экзогенные факторы
- K_i — новые гиперпараметры.

5 Реализация моделей на реальных данных

Рассмотрим датасет с kaggle соревнования по прогнозированию спроса на товары.

```
In [82]: data = pd.read_csv('train.csv', parse_dates=['date'])
         data.head()

Out[82]:
```

	date	store	item	sales
0	2013-01-01	1	1	13
1	2013-01-02	1	1	11
2	2013-01-03	1	1	14
3	2013-01-04	1	1	13
4	2013-01-05	1	1	10

Как мы видим, датасет содержит информацию о магазинах, товарах и продажах. Выберем первый магазин и первый товар и будем предсказывать спрос на выбранный товар в данном магазине, используя последний год для сравнения моделей.

Выделим соответствующие данные из датасета.

```
In [83]: # Задаем магазин и продукт
store, item = 1, 1

# Выделяем только те данные, которые относятся к данному магазину и продукту
data = data[(data['store'] == store) & (data['item'] == item)]

# Дату устанавливаем как индекс
data = data.set_index('date')

# Выделяем данные о продажах
data = data['sales']
```

Разделим данные на трейн и тест для обучения и тестирования соответственно. На тест отправим данные за последний год.

Визуализируем полученные данные. Визуализировать данные надо с самого начала. Это помогает провалидировать данные и выделить некоторые закономерности.


```
In [84]: test_size = 365
data_train = data.iloc[:-test_size]
data_test = data.iloc[-test_size:]

In [85]: plt.figure(figsize=(15, 5))
plt.title('Продажи первого товара в первом магазине')
plt.plot(data_train, label='train')
plt.plot(data_test, label='test')
plt.legend()
```

Out[85]: <matplotlib.legend.Legend at 0x17687bb90>



Видим, что данные обладают годичной сезонностью. Посмотрим теперь, есть ли недельная сезонность.



Некоторая недельная сезонность присутствует.

Теперь вернемся к самой задаче. Прежде чем ее решать, зададим метрики, по которым будем определять, какая из моделей лучше: MSE, MAE и MAPE. Напишем функцию, которая будет считать качество моделей.

```
In [87]: compare_table = None

def add_results_in_comparison_table(method: str, y_true, y_forecast) -> pd.DataFrame:
    """
    Добавляет новую строку в таблицу compare_table с результатами текущей модели.
    Если ранее модель была уже добавлена в таблицу, то старая строка перезаписывается на новую.

    Параметры:
    - method: имя модели.
    - y_true: истинные значения.
    - y_forecast: предсказанные значения.
    """
    # Обращаемся к глобальной переменной
    global compare_table

    # Считаем метрики
    result_row = {
        'method': method,
        'MSE': mean_squared_error(y_true=y_true, y_pred=y_forecast),
        'MAE': mean_absolute_error(y_true=y_true, y_pred=y_forecast),
        'MAPE': mean_absolute_percentage_error(y_true=y_true, y_pred=y_forecast)
    }

    # Записываем результат в таблицу
    if compare_table is None:
        compare_table = pd.DataFrame([result_row])
    else:
        if method in list(compare_table['method']):
            compare_table = compare_table[compare_table['method'] != method]

        compare_table = pd.concat([compare_table, pd.DataFrame([result_row])])
        compare_table.index = np.arange(len(compare_table))
    return compare_table

def mean_absolute_percentage_error(y_true, y_pred) -> float:
    """Считает MAPE для y_true и y_pred"""
    y_true, y_pred = np.array(y_true), np.array(y_pred)
    return np.mean(np.abs((y_true - y_pred) / y_true)) * 100
```


Сначала обучим модель Хольта–Уинтерса и посмотрим, что она выдаст.



Далее посмотрим, как будет предсказывать модель, полученная через `auto_arima`. Обучим модель и получим предсказания.



Как видно, модель не выучила годовую сезонность, что логично, так как она о ней ничего не знала. Использовать же в качестве периода 365 дней плохая идея, потому что:

- модель будет очень долго обучаться с очень большими вычислениями
- это может легко привести к переобучению, так как модель будет смотреть на большое число значений назад

Посмотрим теперь на качество.

	method	MSE	MAE	MAPE
0	HW	59.122581	6.097315	26.687837
1	SARIMA	70.994330	6.650377	28.921262

Качество хуже.

Теперь попробуем учесть годовую сезонность через экзогенные признаки, а точнее через ряды Фурье. Будем рассматривать разложение в ряд Фурье до $K = 2$ первых слагаемых.

```
exog = pd.DataFrame(index=data.index)


exog['sin365'] = np.sin(2 * np.pi * exog.index.dayofyear / 365.25)
exog['cos365'] = np.cos(2 * np.pi * exog.index.dayofyear / 365.25)

exog['sin365_2'] = np.sin(4 * np.pi * exog.index.dayofyear / 365.25)
exog['cos365_2'] = np.cos(4 * np.pi * exog.index.dayofyear / 365.25)

# Разделяем на обучающую и тестовую выборки
exog_to_train = exog.iloc[:-365]
exog_to_test = exog.iloc[-365:]
```

Причем период сезонности равен 365.25, потому что через каждые 4 года в году 366 дней.

Обучим SARIMAX, используя эти экзогенные признаки, и посмотрим на полученные предсказания.



Видно, что качество сильно возросло по сравнению с SARIMA и моделью Хольта–Уинтерса.

6 Заключение

В работе были рассмотрены основные методы прогнозирования временных рядов: экспоненциальное сглаживание, модель Хольта, модель Хольта–Уинтерса, авторегрессия, скользящее среднее, ARMA, ARIMA, SARIMA и ARIMAX, а также подход к выбору гиперпараметров. Отдельное внимание было уделено стационарности и автокорреляции временных рядов.

Практическая часть показала, что выбор модели зависит от структуры ряда. При наличии сезонности эффективнее использовать модель Хольта–Уинтерса или SARIMA, а если сезонностей несколько – SARIMAX, где в качестве экзогенных признаков взяты ряды Фурье.

7 Список литературы

Теория и практика в R:

Hyndman R.J., Athanasopoulos G. *Forecasting: principles and practice*.
<https://www.otexts.org/book/fpp>

В Питоне:

<https://www.coursera.org/learn/data-analysis-applications/home/welcome>